

Benchmark reproduzível de métodos clássicos de aprendizado de máquina para diagnóstico de falhas no Tennessee Eastman Process

Anderson Ricardo de Freitas Rocha

Professor responsável: Clarimar José Coelho

MEI0028 – Modelagem e Simulação · WP1A · PUC Goiás · 2026

O problema

Diagnosticar falhas em uma planta química a partir dos sensores

- Uma planta química é monitorada por dezenas de variáveis acopladas.
- Quando algo sai do normal, é preciso dizer não só que há falha, mas qual é.
- Formulado como classificação: cada leitura dos sensores vai para uma de 21 classes.
- O erro custa caro: parada de produção, perda de produto, risco de segurança.

De onde vem o problema

Trinta anos de uma referência que continua em uso

- 1993 — Downs e Vogel publicam o Tennessee Eastman Process, simulador de uma planta real.
- Vira o ambiente padrão para comparar métodos de diagnóstico de falhas.
- 2012 — Yin et al. fazem a comparação clássica de métodos estatísticos e de aprendizado.
- 2017 — Rieth et al. publicam uma versão estendida com 500 execuções por condição.
- Hoje — a literatura recente usa quase só arquiteturas profundas, com acurácias acima de 99%.

A base de dados

Rieth et al. (2017) · Harvard Dataverse · domínio público

- 52 variáveis: 41 medidas de sensores e 11 comandos de válvula, a cada 3 minutos.
- 21 condições: operação normal e 20 modos de falha.
- 500 execuções independentes por condição, cada uma com semente própria.
- 15,33 milhões de linhas ao todo; 10,08 milhões só no conjunto de teste.
- A falha entra depois do início da execução: 1 hora no treino, 8 horas no teste.


O que a literatura recente não faz

Treze trabalhos de 2019 a 2026, analisados em doze parâmetros

- Só 4 dos 13 declaram dividir os dados por execução completa.
- Dividir por amostra permite ao modelo reconhecer vizinhos já vistos: acurácia inflada.
- Nenhum reporta o MCC, métrica menos sensível ao desbalanceamento entre classes.
- Nenhum mede o custo computacional de todas as famílias no mesmo equipamento.
- Só 3 declaram o que fazem com as amostras anteriores à falha.
- Quem divide por execução usa boosting e não publica o resultado dos métodos clássicos.

Como fizemos

Um protocolo único, declarado por inteiro



A execução completa é a unidade e nunca se parte entre treino e teste. Hiperparâmetros escolhidos só na validação. O teste é lido uma única vez, depois de tudo congelado.


Os seis modelos comparados

Todos sob o mesmo protocolo, os mesmos dados e o mesmo computador

- Regressão logística — a fronteira linear, referência mais simples.
- Árvore de decisão — uma sequência de perguntas sobre as variáveis.
- Random Forest — centenas de árvores votando.
- Gradient boosting — árvores que corrigem o erro das anteriores.
- XGBoost — a versão otimizada do boosting, hoje dominante em dados tabulares.
- SVM aproximado — margem máxima, com o núcleo aproximado para caber na escala.

Resultados


10,08 milhões de amostras de 10.500 execuções nunca vistas



XGBoost lidera (F1 macro 0,817), seguido de Random Forest (0,794) e da árvore isolada (0,741). A ordem entre os modelos se mantém quando se troca o conjunto de execuções avaliadas.

Três falhas que ninguém separa


Falhas 3, 9 e 15 confundem-se com a operação normal



Fora desse bloco a matriz é quase diagonal. O mesmo padrão aparece em trabalhos independentes sobre a mesma base, o que sugere um limite dos dados e não do método.

Desempenho custa tempo

A pergunta que a literatura não responde



A árvore de decisão entrega 91% do F1 macro do XGBoost com inferência 194 vezes mais rápida e modelo sete vezes menor.

O que fica

- Uma linha de base verificável: protocolo, manifesto de divisão e previsões publicados.
- Dividir por amostra em vez de execução infla o F1 macro entre 0,013 e 0,029.
- O rótulo dado às amostras anteriores à falha muda o resultado em até nove pontos.
- Métodos clássicos ainda são competitivos quando o custo entra na comparação.
- Repositório público: github.com/ricardoarfr/MEI0028-modelagem-e-simulacao