

RELATÓRIO DE AUDITORIA DA BASE

Entrega A1 — Tennessee Eastman Process
Rieth et al. (2017), Harvard Dataverse, DOI 10.7910/DVN/6C3JR1

Subprojeto WP1A — Grupo A
MEI0028 — Modelagem e Simulação
Pontifícia Universidade Católica de Goiás

Anderson Ricardo de Freitas Rocha
Professor responsável: Clarimar José Coelho

Goiânia, setembro de 2026

1 Objetivo

Verificar a integridade e a estrutura da base antes de qualquer treinamento, conforme a Etapa 1 do protocolo (§9.1 do WP1A): dimensões, nomes e tipos das colunas, distribuição das classes, número de execuções por classe, amplitude do índice de amostra, valores ausentes, infinitos e duplicatas.

2 Procedimento

- Download dos quatro arquivos .RData a partir do Harvard Dataverse, com conferência dos MD5 publicados.
- Conversão para Parquet em ponto flutuante de 32 bits, executada em R por classe, com escrita incremental, para manter o uso de memória constante.
- Leitura de cada arquivo convertido e verificação programática de cada item acima (02_auditoria.py).

3 Resultado — composição da base

Arquivo	Linhas	Classes	Exec./cl.	Amostras/ex.	Nulos	Infin.	Duplic.
TEP_FaultFree_Training	250.000	1	500	500	0	0	0
TEP_FaultFree_Testing	480.000	1	500	960	0	0	0
TEP_Faulty_Training	5.000.000	20	500	500	0	0	0
TEP_Faulty_Testing	9.600.000	20	500	960	0	0	0

Total: 15.330.000 linhas e 55 colunas por arquivo — faultNumber, simulationRun, sample e as 52 variáveis de processo (41 medidas XMEAS e 11 manipuladas XMV), amostradas a cada três minutos.

4 Verificações por arquivo

TEP_FaultFree_Training

Classes: [0] · execuções por classe: 500 (simulationRun 1 a 500) · amostras por execução: 500 (sample 1 a 500)

Nulos 0 · infinitos 0 · duplicatas de chave 0 · .RData 25 MB convertido em Parquet float32 21 MB

TEP_FaultFree_Testing

Classes: [0] · execuções por classe: 500 (simulationRun 1 a 500) · amostras por execução: 960 (sample 1 a 960)

Nulos 0 · infinitos 0 · duplicatas de chave 0 · .RData 47 MB convertido em Parquet float32 39 MB

TEP_Faulty_Training

Classes: [1 a 20] · execuções por classe: 500 (simulationRun 1 a 500) · amostras por

execução: 500 (sample 1 a 500)

Nulos 0 · infinitos 0 · duplicatas de chave 0 · .RData 494 MB convertido em Parquet
float32 434 MB

TEP_Faulty_Testing

Classes: [1 a 20] · execuções por classe: 500 (simulationRun 1 a 500) · amostras por
execução: 960 (sample 1 a 960)

Nulos 0 · infinitos 0 · duplicatas de chave 0 · .RData 837 MB convertido em Parquet
float32 801 MB

5 Conclusão da auditoria

A base confere integralmente com a descrição publicada por Rieth et al. (2017). As 52 variáveis de processo são as mesmas nos arquivos de treinamento e de teste. Todas as 21 classes têm exatamente 500 execuções, e todas as execuções têm o número esperado de amostras. Não há valores ausentes, infinitos ou duplicatas de chave em nenhum dos quatro arquivos. A base foi aprovada para uso sem qualquer imputação, remoção de registros ou correção.

Evidência completa: results/metadata/auditoria.json,
results/tables/tab01_caracterizacao_base.csv e results/metadata/download_manifest.json
(MD5 conferidos).